고정된 주행 World-Action Model의 첫 상상 패스에서 읽어내는 경량 행동 예측

Imagine Once, Act Fast: Lightweight Action Readout from a Frozen Driving World-Action Model

송용휘[1] and 강현수[1]

[1] 충북대학교 정보통신공학부, 청주, 대한민국, {thddydgnl1937@gmail.com, hskang@chungbuk.ac.kr}

Abstract

DriveWAM과 같은 주행 World-Action Model(WAM)은 5B 비디오 확산 트랜스포머로 미래 영상 잠재(latent)를 상상한 뒤, 같은 백본을 10회 더 실행해 4초 행동 chunk를 denoising하며, 이것이 추론 지연의 가장 큰 항이다. 본 연구는 고정된 백본의 첫 미래 denoising 패스(미래 패스 1) 직후 표현에서 작은 head가 궤적을 읽어낼 수 있는지 묻는다. 이 패스에서 세 트랜스포머 블록을 hook으로 읽고, 1천만 파라미터의 state-fusion head(SF3)로 궤적을 회귀한 뒤 추론을 종료한다. 공개 checkpoint는 갱신하지 않는다. NAVSIM에서는 공식 DriveWAM보다 4.2배, 품질을 유지하는 가장 빠른 저단계 기준보다 2.2배 빠르면서 PDMS 손실은 0.2–0.4점이다. NVIDIA PhysicalAI-AV 공식 test에서는 11.8배 빠르면서 궤적 오차가 DriveWAM과 비슷하다. 공식 단일 표본보다는 낮고, dev 세트에서 표본 4개 평균과 비교하면 ADE는 대등, FDE는 약 0.1 m 높다. 진단 결과 미래 패스 1에 행동 정보 대부분이 이미 들어 있고, 미래 denoising을 더 해도 유의한 이득이 없으며, head 학습 데이터가 늘수록 격차가 꾸준히 줄었다.

Keywords— *World-action model*, 자율주행, 효율적 추론, 비디오 확산 모델, 궤적 계획

A. 문제 정의

DriveWAM [1](6.24B 파라미터, Wan2.2-TI2V-5B [2] 기반)은 자기회귀 video-action 정책이다. 과거 프레임, ego 상태, 안내 문장을 조건으로 미래 영상 잠재를 확산 트랜스포머 3패스로 denoising한 뒤, 4초 행동 chunk를 같은 트랜스포머 10패스로 denoising한다(B10). 본 연구는 백본을 재학습하지 않고, 미래 생성의 어느 시점, 어느 깊이에서 행동을 한 번에 읽어낼 수 있는지 묻는다. 품질은 B10, 그리고 개발(dev) 세트에서 B10 품질을 유지하는 가장 빠른 저단계 변형 B^*와 비교한다. 단계를 줄이는 데는 학습이 필요 없기 때문이다.

B. 독창성

(1) 고정된 *WAM* 자신의 상상에서 읽기. Light-WAM [3]과 두 Faster-WAM 연구 [4, 5]는 가벼운 action expert와 함께 백본을 학습하거나 적응시킨다. 본 연구는 공개 DriveWAM checkpoint를 고정한 채 행동 생성기만 교체하고 미래 패스 1에서 백본을 읽는다. 기여는 head 구조가 아니라 언제, 어디서 읽느냐에 있다. (2) 세 가지 읽기 시점: `current`, `first`, `terminal`(표 2). (3) 사전등록 평가: 분할, B^* 선정, 품질 임계값, head 사양을 결과를 보기 전에 고정했고 잠금 final 세트는 1회만 평가했다. (4) 평가 함정 두 가지: 공개 NAVSIM 백본은 학습 장면을 기억하고 있고(B10 ADE navtrain 0.076 m 대 navtest 0.598 m), PhysicalAI single-seed protocol은 seed에 민감하다(B10 dev ADE 0.82–0.93 m).

C. 알고리즘

고정 백본과 표현 추출. 공식 추론 루프를 재구현해 원본과 비트 단위로 같음을 확인했고, forward hook으로 블록 10, 20, 30을 읽는다. `first` 표현을 쓰면 미래 패스 1 직후 추론을 끝낸다(그림 1). **SF3 head**(998만 파라미터, 백본의 0.16%). head는 Light-WAM action expert의 다층 state-fusion 설계(블록당 학습 query 16개, 융합 MLP, step별 디코딩)를 따른다 [3]. 다른 점은 붙는 대상과 예측하는 것이다. 고정된 DriveWAM 백본에 head만 따로 학습하고, 관측이 아니라 미래 패스 1을 읽으며, ego 상태를 입력으로 받아 step별 정규화 변위와 heading을 낸다(NAVSIM 2 Hz 8 pose, PhysicalAI 10 Hz 40 step). 학습: 40 epoch, 마지막 checkpoint, 평가 데이터로 선택하지 않음. **기준 모델과 통계.** B10과 저단계 변형 B05∼B01-opt(행동 5∼1단계). B^*는 그중 dev 세트에서 B10 품질을 유지하는 가장 빠른 변형이다. 군집 paired bootstrap(2,000회), 지연은 같은 세션에서 번갈아 3회 측정(RTX A5000).

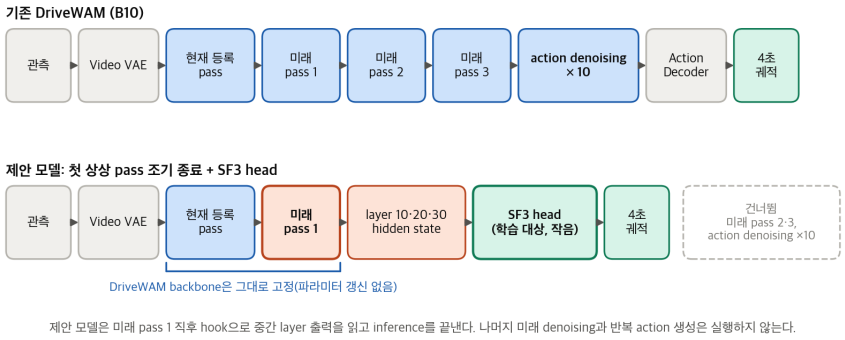


Fig. 1. 공식 DriveWAM 추론(위)과 제안 readout(아래). 백본은 갱신하지 않는다.

D. 실험

설정. NAVSIM v1.1 [6]: 장면 하나 → 4초 궤적 하나, 공식 PDMS. head는 navtrain 92,599장면으로 학습했고 navtest를 로그 단위로 dev 세트(3,250장면)와 잠금 final 세트(8,896장면)로 나눴다. PhysicalAI-AV [7]: clip 하나 → teacher forcing으로 4초 chunk 5개, 공식 ADE/FDE. head는 공개 train 20k clip으로 학습, dev 세트는 val 1,000 clip, final 세트는 공식 test 1k.

	NAVSIM navtest-final		PhysicalAI-AV 공식 test 1k		
모델	PDMS ↑	p50 (ms) ↓	ADE (m) ↓	FDE (m) ↓	p50 (ms) ↓
DriveWAM B10 (공식)	89.67	797.9	0.802	2.384	837.8
B^* (dev에서 선정)	89.65 (B02-opt)	420.7	0.842 (B03-opt)	2.362	434.0
제안 모델 SF3-first, seed 17	89.25	**189.0**	0.750	2.244	**70.9**
제안 모델 SF3-first, seed 29	89.49	**189.0**	0.748	2.244	**70.9**
제안 모델 SF3-first, seed 43	–	–	0.762	2.287	**70.9**

Table 1. 잠금 final 세트(1회 평가). p50: RTX A5000 1장에서 결정 1회 지연의 중앙값. NAVSIM은 policy 호출 전체, PhysicalAI는 실제 기록 등록 이후의 결정 시간(dev 128 clip)을 쟀다. NAVSIM: B10 대비 ΔPDMS $-0.42\,[-0.76, -0.08]$ / $-0.17\,[-0.56, +0.27]$(95% CI).

결과. PhysicalAI: 모든 seed가 공식 단일 표본 B10보다 ADE($-0.040 \sim -0.054$ m)와 FDE($-0.10 \sim -0.14$ m)가 낮고 B^*보다 6.1배 빠르다. NAVSIM: B10보다 PDMS가 0.17–0.42점 낮고 B^*보다 2.2배 빠르다. 충돌(NC)은 0.15–0.17 개선되고 주행 가능 영역 준수(DAC)는 0.35–0.51 악화된다. **미래 패스 하나면 충분하다**(표 2). `first`는 두 벤치마크 모두 `current`보다 확실히 좋고, `terminal`은 `first`보다 유의한 이득이 없다. **head 학습 데이터가 많을수록 격차가 줄어든다**: NAVSIM의 B10 대비 격차는 4k에서 92.6k 장면 사이에 -4.2에서 -0.4 PDMS로 줄었다.

읽기 시점, head 학습 세트	NAVSIM navtest-dev PDMS (seed 17 / 29)	PhysicalAI dev ADE (m, seed 3개 평균)
`current`(관측만), 4k	83.20 / 83.61	0.926
`first`(미래 패스 1), 4k	86.60 / 86.89	0.813
`terminal`(미래 패스 전부), 4k	87.34 / 86.28	0.825
`first`, 20k	89.36 / 90.00	0.762
`first`, 92.6k	90.43 / 90.58	–
DriveWAM B10 (참고)	90.93	0.821

Table 2. 읽기 시점과 head 학습 데이터에 따른 dev 세트 결과. `first` 대 `current`: +3.3 PDMS, ADE -0.11 m(95% CI가 0 제외).

한계. 평균 오차 지표는 결정적 회귀에 유리하므로 DriveWAM보다 정확하다고 주장하지 않는다. PhysicalAI dev 세트에서 B10 표본 4개 평균과 비교하면 ADE는 대등하고 FDE는 약 0.1 m 나쁘다. 읽기 시점 비교는 4k 학습 데이터에서 했다. 코드: `github.com/thddydgnl/drivewam-lightweight-action-readout`.

References

[1] C. Shi et al., DriveWAM, arXiv:2605.28544, 2026.
[2] Team Wan, Wan: open and advanced large-scale video generative models, arXiv:2503.20314, 2025.
[3] Z. Li et al., Light-WAM, arXiv:2606.08242, 2026.
[4] L. Ma et al., Faster-WAM (deep action modules), arXiv:2608.02365, 2026.
[5] W. Zhao et al., Faster-WAM (future conditioning), arXiv:2608.04404, 2026.
[6] D. Dauner et al., NAVSIM, NeurIPS Datasets and Benchmarks, 2024.
[7] NVIDIA, PhysicalAI-Autonomous-Vehicles dataset, 2025.